

# ML HW10

111652039 陳盛芃

## I.Goal is from Forward SDE :

$$dx_t = f(x, t)dt + g(x, t)dW_t$$

Show that it's Probability Flow ODE :

$$dx_t = \left( f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} (g(x_t, t))^2 - \frac{(g(x_t, t))^2}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right) dt$$

**proof :**

### 1. Fokker-Planck 方程 :

根據隨機微分方程理論，SDE 的機率密度  $p(x, t)$  滿足 Fokker-Planck (FP) 方程：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p)$$

### 2. Probability Flow ODE 的連續性方程：

假設存在一個對應的確定性 ODE (Probability Flow ODE)：

$$dx_t = \tilde{f}(x_t, t)dt$$

其中  $\tilde{f}$  是我們待解的漂移函數 (drift function)。

對於這個確定性的流，其機率密度  $p$  必須滿足連續性方程 (Continuity Equation)，這也是 FP 方程在沒有擴散項 (diffusion term) 時的特例：

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(\tilde{f}p)$$

3. 求解  $\tilde{f}$  :

由於 SDE 和其對應的 PF-ODE 描述的是相同的機率密度  $p$  的演化，因此它們的  $\frac{\partial p}{\partial t}$  必須相等。將兩個 FP 方程等同起來：

$$-\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p) = -\frac{\partial}{\partial x}(\tilde{f}p)$$

接著對等式兩邊關於  $x$  進行積分。假設在  $x \rightarrow \pm\infty$  時，機率密度及其導數均  $=0$ ：

$$-(fp) + \frac{1}{2} \frac{\partial}{\partial x}(g^2 p) = -(\tilde{f}p)$$

將上式同乘  $-1$ ，可得：

$$fp - \frac{1}{2} \frac{\partial}{\partial x}(g^2 p) = \tilde{f}p$$

4. 分離  $\tilde{f}$  **By Product Rule** :

將等式兩邊同除以  $p$  (假設  $p \neq 0$ )，我們可以分離出  $\tilde{f}$ ：

$$\tilde{f} = f - \frac{1}{2p} \frac{\partial}{\partial x}(g^2 p)$$

對  $\frac{\partial}{\partial x}(g^2 p)$  使用 Product Rule：

$$\frac{\partial}{\partial x}(g^2 p) = \left(\frac{\partial g^2}{\partial x}\right)p + g^2 \left(\frac{\partial p}{\partial x}\right)$$

將其代回到  $\tilde{f}$  的表達式中：

$$\tilde{f} = f - \frac{1}{2p} \left[ \left(\frac{\partial g^2}{\partial x}\right)p + g^2 \left(\frac{\partial p}{\partial x}\right) \right]$$

分配  $\frac{1}{2p}$ ：

$$\tilde{f} = f - \frac{1}{2} \frac{\partial g^2}{\partial x} - \frac{g^2}{2p} \frac{\partial p}{\partial x}$$

5. 引入 **Score Function**：

We know that  $\frac{\partial}{\partial x} \log p = \frac{1}{p} \frac{\partial p}{\partial x}$ 。By this we have：

$$\tilde{f} = f - \frac{1}{2} \frac{\partial g^2}{\partial x} - \frac{g^2}{2} \frac{\partial}{\partial x} \log p$$

將  $\frac{\partial g^2}{\partial x}$  寫作  $\frac{\partial}{\partial x}(g(x, t)^2)$ ，同時明確寫出變數  $x_t$  和  $t$ ：

$$\tilde{f}(x_t, t) = f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x}(g(x_t, t)^2) - \frac{g(x_t, t)^2}{2} \frac{\partial}{\partial x} \log p(x_t, t)$$

6. 最終結果：

將我們推導出的  $\tilde{f}$  代回到  $dx_t = \tilde{f}(x_t, t)dt$  中，即得到所求的 Probability Flow ODE：

$$dx_t = \left( f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} (g(x_t, t)^2) - \frac{g(x_t, t)^2}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right) dt$$

證明完畢。

## II. AI 的未來與機器學習的基石

### 1. AI 的未來能力

我認為 20 年後 AI 能做到的最重要事情，是從一個「相關性引擎」轉變為一個「因果推論引擎」。具體來說，AI 將有能力建立複雜動態系統的因果模型，並準確回答「反事實 (Counterfactual)」問題。

目前 AI 的瓶頸：目前的 AI，無論是大型語言模型 (LLM) 還是預測模型，本質上都只是在學習「相關性」。它可以告訴我們「歷史上，A 的發生通常與 B 的發生相伴」，但它無法分辨  $A \rightarrow B$  (A 導致 B)、 $B \rightarrow A$  (B 導致 A) 還是  $C \rightarrow (A, B)$  (存在一個隱藏的 C 同時導致 A 和 B)。因此，AI 無法可靠地回答「如果我主動去干預 A，B 會發生什麼變化？」

20 年後的能力與場景：未來的 AI 將能「理解」系統的運作機制。

應用場景：國家級政策模擬

- 問題：一個國家面臨嚴重的通貨膨脹。決策者有兩個選項：(A) 立即升息 2%，或 (B) 實施價格管制。
- 今日 AI：只能回顧歷史數據，給出「在過去，升息相關數據顯示通膨在 6 個月後會下降」這樣的模糊結論。
- 20 年後的 AI (因果引擎)：
  1. AI 首先從過去 50 年的全球經濟數據中，學習到一個包含上百個變數 (利率、匯率、失業率、供應鏈指數等) 的「動態因果 SDE 模型」。

2. 決策者提出反事實提問：「如果我們在 明天強制干預『利率』變數，將其設為 +2%，系統會如何演化？」
3. AI 在其 SDE 模型中進行模擬，預測出：「升息將在 4-6 個月內使通膨下降 3%，但失業率將上升 1.5%，且 GDP 成長將趨緩。同時，模型顯示，價格管制雖然會立即壓低通膨數據，但會 90% 的機率在 3 個月內引發『供應鏈  $A \rightarrow B$ 』的因果鏈斷裂，導致大規模短缺。」

為什麼重要？

這項能力將 AI 從一個被動的「預測工具」轉變為一個主動的「科學與政策顧問」。它讓我們能真正「理解」複雜系統（如經濟、氣候、生物學）的內部運作，並在做出高風險決策前，安全地模擬「未曾發生過的未來」，從而避免災難性的政策失誤。

## 2. 涉及的機器學習類型

這項能力的實現，主要涉及非監督式學習 (Unsupervised Learning) 與監督式學習 (Supervised Learning) 的複雜組合。

原因說明：

1. 非監督式學習（結構發現）：我們的核心任務是「發現」隱藏在數據背後的「因果結構圖」與「動態方程式」。我們擁有的只是原始的時間序列數據，沒有人告訴我們「利率會導致匯率變化」。AI 必須像科學家一樣，從觀測中「自行發現」這些規則。這本質上是一個非監督的「模型發現」或「結構學習」任務。
2. 監督式學習（動態預測）：一旦有了假設的結構（例如  $A$  和  $B$  會影響  $C$ ），我們就需要學習這個結構的具體「參數」或「函數形式」。我們可以將其視為一個監督式問題：利用  $t$  時刻的系統狀態  $(A_t, B_t, C_t)$  作為輸入特徵，去「預測」 $t+1$  時刻的狀態  $C_{t+1}$ （這就是「目標訊號」）。模型會因為「預測錯誤」而受到懲罰，從而不斷修正其對動態方程式的學習。

資料來源：觀測性的時間序列數據 (Observational Time-Series Data)。  
例如：數十年的每日經濟指標 (利率、股價、通膨率)、氣候感測器數據 (溫度、二氧化碳濃度)、生物醫學數據 (病人的心率、血氧、基因表現) 等。

目標訊號：這是一個雙重目標：

1. (非監督) 最大化數據似然性：找到一組 SDE 模型參數  $\theta$ ，使得觀測到的真實數據  $P(\text{Data}|\theta)$  出現的機率最高。
2. (監督) 最小化預測誤差：模型的「目標訊號」是「系統的下一個狀態」。模型學習一個函數  $F$ ，使其對  $X_{t+1}$  的預測  $\hat{X}_{t+1} = F(X_t)$  與真實值之間的誤差 (如 MSE) 最小。

學習回饋：在純粹的觀測學習中，不存在與環境的即時互動 (不像強化學習)。學習回饋來自於模型對「歷史數據」的擬合程度與「未來數據」的預測準確度。

### 3. 第一步的「模型化」

簡化模型問題：在我們能建立一個上百個變數的複雜經濟模型之前，我們必須先解決最根本的問題：AI 能否從觀測數據中，區分「A 導致 B」和「B 導致 A」？

這個簡化問題是一個「二元因果方向分類器」。

概念上的代表性：這個簡化問題是「因果圖發現」的最小單元。一個複雜的上百個節點的因果圖，是由  $N \times N$  個「A 是否導致 B？」的判斷所組成的。如果 AI 連兩個變數的因果方向都無法判定，那麼建立複雜系統就無從談起。這個模型問題在於測試一個核心假設：「不同的因果結構，是否會在 SDE 驅動的動態數據中，留下獨特且可被學習的統計指紋？」

可測試性：這個問題的可測試性非常強，因為我們可以創造「上帝視角的真實答案」：

1. 生成數據：我們手動編寫兩個 SDE 模擬器：

- 世界 1 ( $A \rightarrow B$ )： $dA = f_A(A)dt + \dots$ ， $dB = f_B(B, A)dt + \dots$

- 世界 2 ( $B \rightarrow A$ ) :  $dA = f_A(A, B)dt + \dots$  ,  $dB = f_B(B)dt + \dots$
- 2. 標記數據：我們從「世界 1」生成 1000 條時間序列，標記為「類別 0」；從「世界 2」生成 1000 條，標記為「類別 1」。
- 3. 訓練與測試：我們將 80% 的數據用於訓練一個分類模型，20% 作為測試集。
- 4. 成功指標：模型在測試集上的分類準確率。如果準確率遠高於 50% (例如達到 95% 以上)，就證明模型成功學會了辨識隱藏在動態數據中的「因果指紋」。

所需工具：

1. 數學工具：隨機微分方程 (SDE) 及其數值解法 (如 Euler-Maruyama) 來生成模擬數據。
2. 機器學習工具：循環神經網路 (RNN)，特別是 LSTM 或 GRU。因為因果關係的「指紋」隱藏在時間的動態演化中 (例如  $B$  的變化是否總是微幅滯後於  $A$ )，LSTM 這類模型非常擅長捕捉複雜的時間序列模式。最後，還需要一個標準的監督式分類框架 (如二元交叉熵損失函數和 Adam 優化器)。

### III. Unanswered Questions

筆記中提到 Backward SDE and Probability flow ODE，兩種方式都能將  $t=T$  的雜訊分布轉換為  $t=0$  的資料分布，但如果兩種都能生成的話，在實際應用中選擇使用確定的 PF-ODE 而不是隨機的反向 SED，有甚麼主要優點或是考量