

ML HW11

111652039 陳盛芃

2025 年 11 月 24 日

第一部分：Week 1-10 Unanswered Questions & Research Review

Week1.

- **問題：**課堂中有提及 3 種 Gradient Descent 方法 (Batch, Stochastic, Mini-batch)，但沒有詳細說明優劣及如何判斷何種方法最為適合。
- **是否有對應研究：**是
- **參考文獻 (Reference)：**
 - "An overview of gradient descent optimization algorithms" (Sebastian Ruder, 2016)
 - 連結：[arXiv:1609.04747](https://arxiv.org/abs/1609.04747)
- **說明：**這篇經典的 Review 論文詳細比較了三者：
 - **Batch GD：**穩定但對記憶體要求高，且容易卡在鞍點 (Saddle points)。
 - **SGD：**更新頻繁、速度快，但震盪劇烈。
 - **Mini-batch GD：**目前的主流選擇，結合了前兩者的優點，既能利用矩陣運算加速，又能保持一定的收斂穩定性。通常選擇取決於數據量大小與顯卡記憶體限制 (例如 batch size 32, 64, 128)。

Week2.

- **問題：**此週課程推導了奇數和偶數 neurons 要怎麼運算... 想知道實際在訓練運算時，會訓練多少時間，或是多久會收斂。
- **是否有對應研究：**否
- **說明：**「奇數與偶數 Neurons 的推導」可能是比較數學邏輯的一種推導過程，並沒有甚麼延伸研究的議題，於公開文獻中沒有針對「奇偶神經元分類訓練時間」的直接標準研究。
- **問題重述 (Rephrased for Clarity)：**「在實務中，若將神經網絡層強制區分為處理『奇函數特徵』與『偶函數特徵』的兩組獨立通道，相比於傳統的全連接層 (Fully Connected Layer)，這種架構上的限制會如何影響 Loss 的下降速度？是會因為特徵解耦而加速收斂，還是會因為參數量受限而導致需要更多的 Epochs 才能達到同樣的準確率？」

Week4.

- **問題：**上禮拜提到牛頓法時，提到只有一個點的狀況會因為找不到反矩陣所以不可行，那是否有方法可以代入計算？
- **是否有對應研究：**是
- **參考文獻 (Reference)：**
 - 主題：Quasi-Newton Methods & Levenberg-Marquardt Algorithm
 - 連結：[Springer - Numerical Optimization \(Nocedal & Wright\)](#)
- **說明：**當 Hessian 矩陣奇異 (Singular) 或不可逆時，常用的替代方法包括：
 1. **Quasi-Newton Methods (如 BFGS)：**透過迭代近似 Hessian，避免直接計算反矩陣。
 2. **Levenberg-Marquardt Algorithm：**在 Hessian 中加入一個阻尼項 (Damping term, $H + \lambda I$)，使其變為正定矩陣以保證可逆性，這是訓練神經網絡和非線性最小平方向題中常用的技巧。

Week5.

- **問題：**如果 Σ 是 positive semi-definite matrix 而不是 positive definite matrix，multivariate Gaussian 會變什麼樣子，對模型又會有什麼影響？
 - **是否有對應研究：**是
 - **參考文獻 (Reference)：**
 - 主題：Degenerate Multivariate Normal Distribution
 - 連結：[Wikipedia - Multivariate normal distribution \(Degenerate case\)](#)
 - **說明：**當共變異數矩陣 Σ 僅為半正定 (Positive Semi-definite) 時，該分佈稱為「退化高斯分佈 (Degenerate Multivariate Gaussian)」。
- 這意味著數據並不分佈在完整的 n 維空間中，而是被壓縮在一個較低維度的子空間 (Subspace) 內。這會導致 Σ 不可逆 (Singular)，因此無法直接計算其機率密度函數 (PDF) 中的 Σ^{-1} ，在實作上通常需要使用 Pseudo-inverse 或透過降維 (PCA) 來處理。

Week6.

- **問題：**上週內容提到，我們將一維的非週期函數 f 轉換成 $(\cos(\frac{2\pi x}{L}), \sin(\frac{2\pi x}{L}))$ 來建構 period L 的 f 。想問是對各種的一維非週期 f 都可以這樣做嗎？
- **是否有對應研究：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Periodic Extension & Convergence of Fourier Series (Dirichlet Conditions)
 - 連結：[Paul's Online Math Notes - Convergence of Fourier Series](#)

- **說明：**數學上這稱為函數的「週期延拓 (Periodic Extension)」。只要該函數 f 在區間 $[0, L]$ 上滿足「狄利克雷條件 (Dirichlet conditions)」(即函數是分段連續的，且具有有限個極值點)，就可以將其展開為傅立葉級數。需要注意的是，雖然可以在該區間內收斂，但在邊界處如果原始數值不連續，會產生吉布斯現象 (Gibbs phenomenon)。

Week7.

- **問題：**在 $x_{n+1} = x_n + \eta S(x) + \epsilon, \epsilon \sim N(0, \sigma^2 I)$ 中，如果 $S(x)$ 是已經學習到的箭頭 (score)，為什麼 sampling 還要加一個 ϵ ？
- **是否有對應研究：**是 (Yes)
- **參考文獻 (Reference)：**
 - 文獻標題：“Generative Modeling by Estimating Gradients of the Data Distribution” (Yang Song & Stefano Ermon, 2019)
 - 連結：[arXiv:1907.05600](https://arxiv.org/abs/1907.05600)
- **說明：**如果只沿著 $S(x)$ (Score/Gradient) 移動而不加噪聲 ϵ ，這會變成一般的 Gradient Ascent，最終只會停在機率密度最高的「極值點 (Mode)」，而無法代表整個分佈。加上 ϵ (Langevin noise) 是為了解讓採樣過程保持隨機性，確保生成的樣本能夠遍歷 (explore) 整個真實的數據分佈，而不僅僅是崩塌到單一點。

Week8.

- **問題：**Euler-Maruyama 中，為什麼 drift 乘以 Δt ，但 diffusion 是乘以 $\sqrt{\Delta t}$ ？
- **是否有對應研究：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Properties of Brownian Motion (Wiener Process)
 - 連結：[Wikipedia - Euler-Maruyama method](https://en.wikipedia.org/wiki/Euler-Maruyama_method)
- **說明：**這源自於布朗運動 (Brownian Motion) 的定義。布朗運動增量 dW_t 的變異數 (Variance) 與時間間隔 Δt 成正比，即 $\text{Var}(W_{t+\Delta t} - W_t) = \Delta t$ 。因此，標準差 (Standard Deviation) 為 $\sqrt{\Delta t}$ 。在數值模擬中，Diffusion 項代表隨機波動的幅度，必須符合標準差的尺度，故乘以 $\sqrt{\Delta t}$ ；而 Drift 項是確定性的積分，故乘以 Δt 。

Week10.

- **問題：**筆記中提到 Backward SDE and Probability flow ODE，兩種方式都能將 $t = T$ 的雜訊分布轉換為 $t = 0$ 的資料分布，但如果兩種都能生成的話，在實際應用中選擇使用確定的 PF-ODE 而不是隨機的反向 SDE，有甚麼主要優點或是考量？
- **是否有對應研究：**是 (Yes)
- **參考文獻 (Reference)：**

- 文獻標題：”Score-Based Generative Modeling through Stochastic Differential Equations” (Song et al., ICLR 2021)
- 連結：[arXiv:2011.13456](https://arxiv.org/abs/2011.13456)

• **說明：**在實務上選擇 PF-ODE 通常基於三個關鍵優勢：

1. **採樣速度更快：**PF-ODE 是一個確定性的常微分方程，可以使用現成的高階「黑盒 ODE 解算器」(如 Runge-Kutta 45)。這些解算器支援「自適應步長 (Adaptive Step Size)」，能在誤差允許範圍內自動調整步長，相比於通常需要固定且極小步長的 SDE 解法，能大幅減少計算次數，加速生成過程。
2. **精確的似然計算：**透過 PF-ODE，我們可以利用瞬時變數變換公式 (Instantaneous Change of Variables Formula) 將對數似然函數轉化為積分運算，從而精確計算模型對特定數據的 Log-Likelihood。這在 SDE 框架下非常困難，通常只能估計下界 (ELBO)。
3. **可逆性與隱空間操作：**由於是確定性的，PF-ODE 建立了資料圖片 $x(0)$ 與雜訊 $x(T)$ 之間的唯一雙射 (Bijection)。這意味著我們可以將圖片反推回雜訊空間進行插值 (Interpolation) 或編輯，然後再生成回來，這是隨機的 SDE 難以做到的。

部分問題與 ML 知識沒有太實際關聯，故無呈現。

第二部分：Toy Model 設計構想 - 二元因果方向分類器

為了探討「因果推論引擎」，我試著設計了一個簡化的「二元因果方向分類器」作為簡易操作實驗模型。此模型旨在驗證 ML 是否能從觀測數據的動態變化中，識別出變數間的相互驅動關係。

1. 問題定義

在擴展真實世界中包含大量變數的複雜經濟模型之前，先將問題縮減至最簡單的部分：能否辨別是「A 導致 B」($A \rightarrow B$) 還是「B 導致 A」($B \rightarrow A$)。

- 假設：不同的因果結構應當會在數據的時間動態中留下獨特的 Statistical Fingerprints。即使沒有加入自己額外增加的數據，SDE 時間序列中的 Lag 與相關性模式理論上應該要是能區分的。
- 目標：在給定一個雙變數時間序列 $\mathcal{D} = \{(x_t, y_t)\}_{t=0}^T$ 的前提下，嘗試著去訓練一個二元分類器，判斷其背後的因果機制是 Class 0 ($X \rightarrow Y$) 還是 Class 1 ($Y \rightarrow X$)。

2. 模型設定

本計畫將採用「Simulation-Based Learning」的方法，透過求解 SDE 生成具備已知資訊的數據，並使用循環神經網路進行監督式學習。

I. 數據生成設計 本計畫將設定兩個世界的 SDE 模擬器來生成訓練數據：

- **World 0 ($X \rightarrow Y$):** 設定 X 為獨立進行的 Ornstein-Uhlenbeck 過程，而 Y 的 drift 包含與 X 的耦合項，代表 X 對 Y 的單向影響。

$$dX_t = f_X(X_t)dt + dW_1, \quad dY_t = f_Y(Y_t, X_t)dt + dW_2$$

- **World 1 ($Y \rightarrow X$):** 和 World 0 中方程式形式邏輯互換，設定 Y 獨立進行，而 X 受 Y 影響。

$$dX_t = f_X(X_t, Y_t)dt + dW_1, \quad dY_t = f_Y(Y_t)dt + dW_2$$

II. 模型架構設計 由於因果訊號往往隱藏在時間序列的滯後與動態變化中（例如：原因的變化先於結果），計畫採用 ****LSTM (Long Short-Term Memory)**** 網絡作為核心架構。

- 輸入層：接收長度為 T 的雙變數時間序列張量 (x_t, y_t) 。
- 隱藏層：利用 LSTM 單元提取時間依賴特徵，捕捉變數間的先後關係。
- 輸出層：連接 Fully Connected Layer 與 Sigmoid function，輸出屬於 Class 1 ($Y \rightarrow X$) 的機率。

3. 預期實驗結果

1. 數據集準備：分別從 World 0 與 World 1 各生成 1,000 條時間序列樣本，並標記對應的 Label (0 或 1)。
2. 訓練：將數據以 8:2 比例分割為訓練集與測試集。使用 Binary Cross-Entropy 作為 Loss Function，並透過 Adam 優化器進行參數更新。
3. 評估指標：使用 Accuracy 作為主要指標。若模型準確率顯著高於 50%，即證明此設定模型成功學會了辨識隱藏在動態數據中的因果特徵。

4. 預期學習目標

透過此計畫的設計與實作，預期能驗證「因果結構可學習性」的可行性。如果簡單的 LSTM 能夠區分線性的 SDE 因果方向，這將為未來使用更複雜的圖神經網路 (GNN) 來解構高維度經濟或氣候系統的因果圖奠定理論基礎。