

ML HW10

111652039 陳盛芃

2025 年 11 月 24 日

第一部分：Week 1-10 Unanswered Questions & Research Review

1. 關於一維非週期函數的傅立葉轉換

- **原始問題：**上週內容提到，我們將一維的非週期函數 f 轉換成 $(\cos(\frac{2\pi x}{L}), \sin(\frac{2\pi x}{L}))$ 來建構 period L 的 f 。想問是對各種的一維非週期 f 都可以這樣做嗎？
- **是否有對應研究/解答：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Periodic Extension & Convergence of Fourier Series (Dirichlet Conditions)
 - 連結：[Paul's Online Math Notes - Convergence of Fourier Series](#)
- **說明：**數學上這稱為函數的「週期延拓 (Periodic Extension)」。只要該函數 f 在區間 $[0, L]$ 上滿足「狄利克雷條件 (Dirichlet conditions)」(即函數是分段連續的，且具有有限個極值點)，就可以將其展開為傅立葉級數。需要注意的是，雖然可以在該區間內收斂，但在邊界處如果原始數值不連續，會產生吉布斯現象 (Gibbs phenomenon)。

2. 關於 Euler-Maruyama 方法中的 Scaling

- **原始問題：**Euler-Maruyama 中，為什麼 drift 乘以 Δt ，但 diffusion 是乘以 $\sqrt{\Delta t}$ ？
- **是否有對應研究/解答：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Properties of Brownian Motion (Wiener Process)
 - 連結：[Wikipedia - Euler-Maruyama method](#)
- **說明：**這源自於布朗運動 (Brownian Motion) 的定義。布朗運動增量 dW_t 的變異數 (Variance) 與時間間隔 Δt 成正比，即 $\text{Var}(W_{t+\Delta t} - W_t) = \Delta t$ 。因此，標準差 (Standard Deviation) 為 $\sqrt{\Delta t}$ 。在數值模擬中，Diffusion 項代表隨機波動的幅度，必須符合標準差的尺度，故乘以 $\sqrt{\Delta t}$ ；而 Drift 項是確定性的積分，故乘以 Δt 。

3. 關於 Langevin Dynamics 的採樣噪聲

- **原始問題：**在 $x_{n+1} = x_n + \eta S(x) + \epsilon, \epsilon \sim N(0, \sigma^2 I)$ 中，如果 $S(x)$ 是已經學習到的箭頭 (score)，為什麼 sampling 還要加一個 ϵ ？
- **是否有對應研究/解答：**是 (Yes)
- **參考文獻 (Reference)：**
 - 文獻標題：“Generative Modeling by Estimating Gradients of the Data Distribution” (Yang Song & Stefano Ermon, 2019)
 - 連結：[arXiv:1907.05600](https://arxiv.org/abs/1907.05600)
- **說明：**如果只沿著 $S(x)$ (Score/Gradient) 移動而不加噪聲 ϵ ，這會變成一般的 Gradient Ascent，最終只會停在機率密度最高的「極值點 (Mode)」，而無法代表整個分佈。加上 ϵ (Langevin noise) 是為了讓採樣過程保持隨機性，確保生成的樣本能夠遍歷 (explore) 整個真實的數據分佈，而不僅僅是崩塌到單一點。

4. 關於多元高斯分佈的矩陣性質

- **原始問題：**如果 Σ 是 positive semi-definite matrix 而不是 positive definite matrix，multivariate Gaussian 會變什麼樣子，對模型又會有什麼影響？
- **是否有對應研究/解答：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Degenerate Multivariate Normal Distribution
 - 連結：[Wikipedia - Multivariate normal distribution \(Degenerate case\)](https://en.wikipedia.org/wiki/Multivariate_normal_distribution#Degenerate_case)
- **說明：**當共變異數矩陣 Σ 僅為半正定 (Positive Semi-definite) 時，該分佈稱為「退化高斯分佈 (Degenerate Multivariate Gaussian)」，這意味著數據並不分佈在完整的 n 維空間中，而是被壓縮在一個較低維度的子空間 (Subspace) 內。這會導致 Σ 不可逆 (Singular)，因此無法直接計算其機率密度函數 (PDF) 中的 Σ^{-1} ，在實作上通常需要使用 Pseudo-inverse 或透過降維 (PCA) 來處理。

5. 關於牛頓法的替代方案

- **原始問題：**上禮拜提到牛頓法時，提到只有一個點的狀況會因為找不到反矩陣所以不可行，那是否有 的方法可以代入計算？
- **是否有對應研究/解答：**是 (Yes)
- **參考文獻 (Reference)：**
 - 主題：Quasi-Newton Methods & Levenberg-Marquardt Algorithm
 - 連結：[Springer - Numerical Optimization \(Nocedal & Wright\)](https://springer.com/numerical-optimization)
- **說明：**當 Hessian 矩陣奇異 (Singular) 或不可逆時，常用的替代方法包括：

1. **Quasi-Newton Methods (如 BFGS)**：透過迭代近似 Hessian，避免直接計算反矩陣。
2. **Levenberg-Marquardt Algorithm**：在 Hessian 中加入一個阻尼項 (Damping term, $H + \lambda I$)，使其變為正定矩陣以保證可逆性，這是訓練神經網絡和非線性最小平方向題中常用的技巧。

6. 關於 Gradient Descent 方法的選擇

- **原始問題**：課堂中有提及 3 種 Gradient Descent 方法 (Batch, Stochastic, Mini-batch)，但沒有詳細說明優劣及如何判斷何種方法最為適合。
- **是否有對應研究/解答**：是 (Yes)
- **參考文獻 (Reference)**：
 - 文獻標題：“An overview of gradient descent optimization algorithms” (Sebastian Ruder, 2016)
 - 連結：[arXiv:1609.04747](https://arxiv.org/abs/1609.04747)
- **說明**：這篇經典的 Review 論文詳細比較了三者：
 - **Batch GD**：穩定但對記憶體要求高，且容易卡在鞍點 (Saddle points)。
 - **SGD**：更新頻繁、速度快，但震盪劇烈。
 - **Mini-batch GD**：目前的主流選擇，結合了前兩者的優點，既能利用矩陣運算加速，又能保持一定的收斂穩定性。通常選擇取決於數據量大小與顯卡記憶體限制 (例如 batch size 32, 64, 128)。

7. 關於奇數/偶數 Neurons 的訓練收斂

- **原始問題**：此週課程推導了奇數和偶數 neurons 要怎麼運算... 想知道實際在訓練運算時，會訓練多少時間，或是多久會收斂。
- **是否有對應研究/解答**：否 (Open Problem / Context Dependent)
- **說明**：由於「奇數與偶數 Neurons 的特定推導」屬於本課程特定的理論架構 (可能是針對特定的基底函數、對稱性或 Fourier Neural Operators 的特例)，在公開文獻中沒有針對「奇偶神經元分類訓練時間」的直接標準研究。這高度取決於網路架構的深度、數據集的複雜度以及硬體效能。
- **問題重述 (Rephrased for Clarity)**：「在實務工程上，若我們將神經網絡層強制區分為處理『奇函數特徵』與『偶函數特徵』的兩組獨立通道，相比於傳統的全連接層 (Fully Connected Layer)，這種架構上的限制會如何影響 Loss 的下降速度？是會因為特徵解耦而加速收斂，還是會因為參數量受限而導致需要更多的 Epochs 才能達到同樣的準確率？」

8. 關於 Backward SDE 與 Probability Flow ODE 的選擇

- **原始問題**：筆記中提到 Backward SDE and Probability flow ODE，兩種方式都能將 $t = T$ 的雜訊分布轉換為 $t = 0$ 的資料分布，但如果兩種都能生成的話，在實際應用中選擇使用確定的 PF-ODE 而不是隨機的反向 SDE，有甚麼主要優點或是考量？

- 是否有對應研究/解答：是 (Yes)
- 參考文獻 (Reference)：
 - 文獻標題：”Score-Based Generative Modeling through Stochastic Differential Equations” (Song et al., ICLR 2021)
 - 連結：[arXiv:2011.13456](https://arxiv.org/abs/2011.13456)
- 說明：在實務上選擇 PF-ODE 通常基於三個關鍵優勢：
 1. **採樣速度更快**：PF-ODE 是一個確定性的常微分方程，可以使用現成的高階「黑盒 ODE 解算器」(如 Runge-Kutta 45)。這些解算器支援「自適應步長 (Adaptive Step Size)」，能在誤差允許範圍內自動調整步長，相比於通常需要固定且極小步長的 SDE 解法，能大幅減少計算次數，加速生成過程。
 2. **精確的似然計算**：透過 PF-ODE，我們可以利用瞬時變數變換公式 (Instantaneous Change of Variables Formula) 將對數似然函數轉化為積分運算，從而精確計算模型對特定數據的 Log-Likelihood。這在 SDE 框架下非常困難，通常只能估計下界 (ELBO)。
 3. **可逆性與隱空間操作**：由於是確定性的，PF-ODE 建立了資料圖片 $x(0)$ 與雜訊 $x(T)$ 之間的唯一雙射 (Bijection)。這意味著我們可以將圖片反推回雜訊空間進行插值 (Interpolation) 或編輯，然後再生成回來，這是隨機的 SDE 難以做到的。

第二部分：Toy Model 設計構想 - 二元因果方向分類器

爲了邁向「因果推論引擎」的 20 年願景，我設計了一個簡化的「二元因果方向分類器」作爲第一步的可實作模型問題。這個模型旨在驗證機器學習是否能從觀測數據的動態變化中，自動識別變數間的驅動關係。

1. 問題定義 (Problem Definition)

在建立包含上百個變數的複雜經濟模型之前，我們必須先解決最根本的問題：區分「A 導致 B」($A \rightarrow B$) 與「B 導致 A」($B \rightarrow A$)。

- **核心假設**：不同的因果結構會在數據的時間動態中留下獨特的「統計指紋」(Statistical Fingerprints)。即使沒有介入實驗，SDE 驅動的時間序列中的滯後 (Lag) 與相關性模式應當是可被區分的。
- **任務目標**：給定一個雙變數時間序列 $\mathcal{D} = \{(x_t, y_t)\}_{t=0}^T$ ，訓練一個二元分類器判斷其背後的因果機制是 Class 0 ($X \rightarrow Y$) 還是 Class 1 ($Y \rightarrow X$)。

2. 擬定解法與模型 (Proposed Method)

本計畫將採用「模擬學習 (Simulation-Based Learning)」的方法，透過求解隨機微分方程 (SDE) 生成具有已知標籤的數據，並使用循環神經網路進行監督式學習。

A. 數據生成計畫 (SDE Generation Plan) 我們將設計兩個「世界」的 SDE 模擬器來生成訓練數據：

- **World 0 ($X \rightarrow Y$)**: 設定 X 爲獨立演化的 Ornstein-Uhlenbeck 過程，而 Y 的漂移項 (drift) 包含與 X 的耦合項，代表 X 對 Y 的單向影響。

$$dX_t = f_X(X_t)dt + dW_1, \quad dY_t = f_Y(Y_t, X_t)dt + dW_2$$

- **World 1 ($Y \rightarrow X$)**: 方程式形式對稱交換，設定 Y 獨立演化，而 X 受 Y 驅動。

$$dX_t = f_X(X_t, Y_t)dt + dW_1, \quad dY_t = f_Y(Y_t)dt + dW_2$$

B. 模型架構設計 (Model Architecture) 由於因果訊號往往隱藏在時間序列的滯後與動態變化中（例如：原因的變化先於結果），計畫採用 **LSTM (Long Short-Term Memory)** 網絡作爲核心架構。

- **輸入層**：接收長度爲 T 的雙變數時間序列張量 (x_t, y_t) 。
- **隱藏層**：利用 LSTM 單元提取時間依賴特徵，捕捉變數間的先後演化關係。
- **輸出層**：連接全連接層 (Fully Connected Layer) 與 Sigmoid 激活函數，輸出屬於 Class 1 ($Y \rightarrow X$) 的機率。

3. 預期實驗規劃 (Experimental Plan)

1. **數據集準備**：分別從 World 0 與 World 1 各生成 1,000 條時間序列樣本，並標記對應的 Label (0 或 1)。
2. **訓練流程**：將數據以 8:2 比例分割為訓練集與測試集。使用二元交叉熵 (Binary Cross-Entropy) 作為 Loss Function，並透過 Adam 優化器進行參數更新。
3. **評估指標**：使用分類準確率 (Accuracy) 作為主要指標。若模型準確率顯著高於 50% (隨機猜測)，即證明模型成功學會了辨識隱藏在動態數據中的因果特徵。

4. 預期學習目標 (Expected Insights)

透過此 Toy Model 的設計與實作，我們預期能驗證「因果結構可學習性」的可行性。如果簡單的 LSTM 能夠區分線性的 SDE 因果方向，這將為未來使用更複雜的圖神經網路 (GNN) 來解構高維度經濟或氣候系統的因果圖奠定理論基礎。